

온통청년 정책 RAG MVP 데이터 구축 보고서

수집 → 정규화 → MVP 400 문서 선정 → RAG 문서 스키마 → 평가질문 47개와 qrels 답안지 구축

API 수집

2,728건

MVP 문서

400개

평가 질문

47개

qrels

50행

생성일: 2026-08-24 21:49:15 KST

1. 한눈에 보는 현재 상태

2번 담당 범위: 데이터 수집, 정제, 문서 스키마, 평가셋/qrels 준비까지 완료



현재까지 만든 핵심 산출물은 검색 대상 문서 400개와 평가 질문 47개, 그리고 문서 단위 정답표(qrels) 50행이다. qrels가 질문 수보다 많은 이유는 3개 질문에서 정답으로 인정해야 하는 문서가 2개씩 있기 때문이다.

아직 하지 않은 일은 chunking, chunk_id 생성, ground_truth_chunk_ids 매핑, embedding, Chroma 적재, 실제 retrieval 평가다. 이 부분은 다음 담당자가 이어서 수행한다.

2. 원본 데이터 수집

온통청년 청년정책 API에서 전체 정책을 JSON으로 수집

항목	값
API endpoint	https://www.youthcenter.go.kr/go/ythip/getPlcy
최종 수집 건수	2,728건
API key 저장 여부	파일에 저장하지 않음
중복 정책번호	0건
수집 방식	pageSize=10 기본 수집 후 실패 페이지는 pageSize=1로 복구

구현 관점에서는 API 키를 스크립트에 직접 박아 넣지 않고 환경변수로 받는 방식으로 다뤘다. 원본 API 응답은 raw 영역에 보존하고, 검색과 분석에 편한 catalog/jsonl을 별도로 생성했다.

```
GET /go/ythip/getPlcy?apiKeyNm=...&pageNum=1&pageSize=10&rtntype=json
→ raw page JSON 보존
→ 실패 페이지는 pageSize=1로 재요청
→ JSONL + CSV catalog 생성
```


3. 원본 분류의 문제

API 원본 분류명은 중복 표기, 옛 명칭, 복합 분류가 섞여 있어 그대로 쓰기 어렵다


예를 들어 원본에는 '복지문화', '금융 복지 문화', '교육', '교육 직업훈련', '참여권리', '참여 기반'처럼

비슷한 의미가 다른 문자열로 들어온다. 그래서 이후 선정과 평가가 흔들리지 않도록 정규화 규칙을 먼저 만들었다.

원본 대분류 Top 8



정규화 후 대분류



4. 분류명 정규화 기준

정책 분야를 MVP에서 균형 있게 다루기 위한 공통 분류 체계

정규화 대분류	건수	설명
일자리	1076	취업, 창업, 재직자
복지문화	658	건강, 문화활동, 예술인지원, 금융/복지 성격
참여권리	388	청년참여, 권익보호, 정책인프라
교육	323	교육비지원, 미래역량강화, 온라인교육
주거	282	전월세, 주택, 거주지, 기숙사
UNKNOWN	1	분류값이 비어 있거나 매핑 불가


정규화 결과 전체 2,728건 중 UNKNOWN은 1건뿐이었다. 이 기준 덕분에 MVP 400개를 카테고리별로 의도적으로 뽑을 수 있고, 나중에 평가 질문도 분야별로 균형을 볼 수 있다.

5. MVP 400개 선정


전체 2,728건을 모두 쓰기 전, 실험 가능한 고품질 corpus 400개를 먼저 구성

선정 규칙은 category_target + primary_mclsf_balance + document_quality_score_desc였다. 즉 분야별 목표 수를 먼저 잡고, 그 안에서 중분류 균형과 문서 품질점수를 반영해 400건을 뽑았다.

MVP 400 대분류 분포



MVP 중분류 Top 10



6. 문서 품질점수의 의미

검색 문서로 쓸 만한 정책인지 판단하기 위해 핵심 필드의 충실도를 점수화

반영 필드	품질 신호	왜 중요한가
정책명	title_ok	문서를 식별하고 검색 결과를 설명할 때 필요
정책 설명	description_rich	문서의 목적과 상황 검색 단서를 제공
지원 내용	support_content_rich	사용자가 묻는 혜택의 핵심 답변
지원 대상/자격	target_condition_present	eligibility 질문의 근거
신청 기간	application_period_present	period 질문의 근거
신청 방법	application_method_present	application_method 질문의 근거
제출 서류	submission_docs_present	documents 질문의 근거
URL	url_present	검수와 실제 안내 링크
키워드	keyword_present	분류와 보조 검색 단서
정규화 상태	normalization_ok	카테고리 균형과 후속 분석 안정성

선정된 400개 품질점수: 최소 86 / 평균 102.438 / 최대 106

7. RAG용 documents.jsonl 스키마

정책 1건을 검색 가능한 document 1건으로 변환

document_id

검색/평가에서 쓰는 고유 ID

source / url

출처와 원문 링크

retrieval_text

chunking과 검색에 사용할 본문

raw_record

API 원본 60개 필드 보존

title

정책명

content

사람이 읽는 정책 본문

metadata

분류, 기관, 기간, 나이, 지역 등

핵심은 원본 API 값을 잃지 않는 것이다. 검색용 텍스트를 만들더라도 raw_record를 그대로 보존해 나중에 필드 누락, 오분류, 답변 근거 문제를 다시 추적할 수 있게 했다.

8. 문서 예시

documents.jsonl의 실제 정책 1건이 어떤 모양인지


필드	예시
document_id	ontong_youth_20250331005400210675
title	청년창업 특례보증
category	일자리 / 창업
url	https://www.gjsinbo.or.kr

retrieval_text 앞부분

정책명: 청년창업 특례보증 / / 정책 요약: 청년창업기업에 대한 특례보증과 이자지원으로 청년기업 자금력 문제 완화 및
청년 창업 활성화 도모 / / 지원 내용: ○ 업체당 최대 50백만원 / ○ 상환방법 / - 1년 일시상환(최대 5년 연장
가능) / - 5년 분할상환 (1년 거치 4년 원금균등분할) / ○ 이자지원 : 3%(1년간) / ○ 보증비율 : 100%
/ ○ 보증료율 : 연 0.5% / ○ 대출금리 : 은행별 변동금리(광주은행, 신한은행, 우리은행, NH농협은행,
KB국민은행, IBK기업은행, KEB하나은행) / / ※ 자금 소진 시 신청종료 / / 추가 신청 자격: 광주광역시 소재
청년 창업기업* (* 만 39세 이하, 업력 7년 이내인 소기업·소상공인) / / "2025년 광주광역시 소상공인 특례보증
지원사업" 대상 업체 제외 / / 신청 기간: 20250312 ~ 20251231 / / 사업 기간: 예산 소진 시 마감
/ / 신청 방법: ○ 신청 및 접수(기업 → 광주신용보증재단) / - 광주신용보증재단 홈페이지에서 상담예약 후 내방하여
접수 / - 재단 홈페이지 : www.gjsinbo.or.kr

9. 문서 길이 분포

chunking 전 corpus의 retrieval_text 길이 확인



지표	값
문서 수	400
최소	297
평균	1013.9
중앙값	921
최대	3617

길이 분포를 확인한 이유는 chunk size 실험의 출발점을 잡기 위해서다. 너무 짧은 문서와 긴 문서의 비율을 알아야 300/500/700자 같은 chunk size 비교가 의미 있어진다.

10. 평가 질문 생성과 검수 흐름

처음 만든 질문을 그대로 쓰지 않고, 사람 검수와 재수정을 거쳐 품질을 올림



V1은 정책명이 과도하게 드러나거나 너무 포괄적인 질문이 많아 평가 질문으로 부적합했다. 그래서 V2 refined에서는 질문 유형을 나누고, query/source_title/reference_answer의 삼각관계를 중심으로 재검수했다.


최종적으로 원본 V2에서 바로 통과한 14개, label 2를 고친 뒤 통과한 25개, qrels/질문/정답문서 조정으로 복구한 8개를 합쳐 47개 평가 질문을 만들었다.

11. 최종 평가 질문 47개의 구성


질문 유형과 정책 분야 분포

질문은 정책 발견형(specific_policy_search)과 정보 조회형(application_method, support_content, eligibility, period, required_documents 등)으로 나뉜다. MVP에서는 완벽한 균형보다 먼저 채점 가능한 고품질 질문 확보를 우선했다.

질문 유형 분포



평가 질문 대분류 분포



12. eval_questions와 qrels의 차이

문제지와 채점용 답안지는 역할이 다르다

eval_questions.csv/jsonl

질문 문장, 정답 정책명, 참고 답변(reference_answer), 대표
정답 문서 ID를 담는다. 사람이 검토하기 좋은 문제지 역할이다.

qrels.csv/jsonl

query_id와 document_id의 연결만
담는다. 검색기가 어떤 문서를 찾으면 정답으로
채점할지 알려주는 답안지다.

구분	질문/답 문장	정답 문서 ID	사용자
eval_questions	있음	있음	사람 검수, 평가 실행 입력
qrels	없음	있음	채점 코드

13. 실제 질문과 답안지 예시

질문에 대한 답과 qrels가 가리키는 문서는 서로 다른 층위

항목	값
query_id	oy_eval_v2r_q0004
질문	광주에서 창업을 준비하는 청년을 위한 대출 또는 보증 지원은 어떤 방식으로 신청하나요?
정답 정책명	청년창업 특례보증
qrels document_id	ontong_youth_20250331005400210675

reference_answer

○ 신청 및 접수(기업 → 광주신용보증재단) - 광주신용보증재단 홈페이지에서 상담예약 후 내방하여 접수 - 재단 홈페이지 : www.gjsinbo.or.kr - 재단 영업점 · 광산지점 062)950-0080 · 동구지점 062)958-1400 · 서구지점 062)958-1420 · 남구지점 062)958-1440 · 북구지점 062)958-1460 · 송정지점 062)958-1480

실제 답변은 신청 방법 문장이지만, qrels는 그 문장을 저장하지 않고 답변을 포함한 정답 문서 ID만 가리킨다.

14. multi-qrels가 필요한 이유

정답 문서가 하나만 있다고 가정하면 정상 검색 결과가 오답 처리될 수 있다

oy_eval_repair_q0037 | 정답 문서 2개

서울청년문화패스와 서울청년문화패스 지원 두 문서가 같은 지원 내용을 담하므로 둘 다 정답으로 인정.

oy_eval_repair_q0038 | 정답 문서 2개

2025년 전국민마음투자지원사업과 전국민 마음투자 지원사업이 같은 심리상담 바우처 정책을 담하므로 둘 다 정답으로 인정.

oy_eval_repair_q0080 | 정답 문서 2개

광주 남구 청년 자격증 취득 지원 동일 제목/동일 내용 문서 2건을 모두 정답으로 인정.

예: 서울청년문화패스와 서울청년문화패스 지원처럼 같은 질문에 답할 수 있는 형제 문서가 corpus에 같이 있으면 두 문서 모두 relevance=1로 넣어야 한다. 그렇지 않으면 검색기가 맞는 형제 문서를 찾아도 qrels에 없어서 오답이 된다.

15. 보류 8건을 어떻게 복구했는가

질문 자체 문제와 답안지 문제를 분리해서 처리

query_id	조치	최종 처리
oy_eval_repair_q0021	question_refined	전국 유사 사업과 구분되도록 '세종시 자체 배정' 조건을 추가해 세종 문서 단일 정답으로 유지.
oy_eval_repair_q0030	question_refined	산림청년포럼/시너지캠프와 구분되도록 '교육 프로그램 20종 공모·운영' 슬롯을 추가.
oy_eval_repair_q0032	question_refined	2026년 문서와 구분되도록 '2025학년도'를 명시.
oy_eval_repair_q0037	multi_qrels_added	서울청년문화패스와 서울청년문화패스 지원 두 문서가 같은 지원 내용을 답하므로 둘 다 정답으로 인정.
oy_eval_repair_q0038	multi_qrels_added	2025년 전국민마음투자지원사업과 전국민 마음투자 지원사업이 같은 심리상담 바우처 정책을 답하므로 둘 다 정답으로 인정.
oy_eval_repair_q0039	question_refined	정답 문서의 실제 주소 요건이 전라남도라 '광주'를 '전남'으로 수정.
oy_eval_repair_q0077	answer_document_reassigned	제목과 신청방법에 장애인 유형이 명시된 '평생교육이용권[일반·장애인] 지원' 문서로 정답 문서를 재지정.
oy_eval_repair_q0080	multi_qrels_added	광주 남구 청년 자격증 취득 지원 동일 제목/동일 내용 문서 2건을 모두 정답으로 인정.

16. 최종 산출물 위치

3번 담당자에게 넘길 때 가장 중요한 파일

역할	파일
MVP 검색 corpus	C:\말뚱가리\data\processed\ontong_youth_mvp_400_documents\documents.jsonl
문서 스키마 설명	C:\말뚱가리\data\processed\ontong_youth_mvp_400_documents\DOCUMENT_SCHEMA.md
평가 질문	C:\말뚱가리\data\processed\ontong_youth_eval_questions_v2_final_47\eval_questions.jsonl
평가 질문 CSV	C:\말뚱가리\data\processed\ontong_youth_eval_questions_v2_final_47\eval_questions.csv
문서 단위 qrels	C:\말뚱가리\data\processed\ontong_youth_eval_questions_v2_final_47\qrels.jsonl
qrels CSV	C:\말뚱가리\data\processed\ontong_youth_eval_questions_v2_final_47\qrels.csv

17. 다음 담당자에게 넘기는 작업

2번은 문서와 평가셋 준비까지, 3번은 chunking 이후 평가 준비

3번이 입력으로 받을 것

documents.jsonl, eval_questions.jsonl,
qrels.jsonl. qrels는 document_id 기준 정답표이며
아직 chunk_id 기준이 아니다.

3번이 생성할 것

chunks.jsonl, chunk_id,
document_id→chunk_id 매핑,
ground_truth_chunk_ids. 이후
embedding과 Chroma 적재가
가능해진다.

중요: chunk size나 overlap이 바뀌면 chunk_id와
ground_truth_chunk_ids도 바뀐다. 따라서 지금 만든 qrels(document_id
기준)는 고정 기준으로 두고, chunking 실험마다 정답 chunk를 다시 매핑해야 한다.

18. 아직 하지 않은 일과 주의점

이번 보고서는 2번 단계의 산출물 설명서

항목	상태	이유
Chunking	미수행	3번 담당 범위
Embedding	미수행	chunk가 확정된 뒤 수행
Chroma 적재	미수행	embedding 이후 수행
ground_truth_chunk_ids	미생성	chunking 설정마다 달라짐
전체 2,728건 실서비스 corpus	미확정	MVP 400으로 먼저 실험
상황 설명형 질문 보강	권장	현재 47개는 known-item 성격이 일부 존재

현재 47개는 평가를 시작하기에는 충분하지만, 더 안정적인 MVP 평가를 위해서는 상황 설명형 질문을 추가로 만들어 50~100개 수준까지 확장하는 것이 좋다.

19. 구현 스크립트 요약

주요 변환은 재실행 가능한 스크립트로 남겨 두었다

스크립트	역할
normalize_ontong_youth_catalog.py	원본 catalog/raw JSONL을 정규화 분류 체계로 변환
select_ontong_youth_mvp_400.py	품질점수와 카테고리 목표 기반으로 MVP 400개 선정
build_ontong_youth_mvp_documents.py	RAG용 documents.jsonl과 schema 문서 생성
generate_ontong_youth_eval_question_candidates_v2_refined.py	V2 refined 평가 질문 후보 생성
repair_ontong_youth_eval_label2.py	보류 33건을 수정 질문 후보로 변환
build_ontong_youth_eval_final_47.py	검수/수정 결과를 최종 eval_questions와 qrels로 조립
build_ontong_youth_project_pdf_report.py	현재 PDF 보고서 생성

20. 결론

2번 담당 산출물은 MVP 기준으로 인계 가능한 상태

온통청년 API 원본 2,728건에서 출발해 정규화된 정책 catalog를 만들고, 그중 품질과 분야 균형을 고려해 MVP 400개 문서를 선정했다. 이후 RAG용 documents.jsonl 스키마를 만들고, 검색 평가를 위한 질문 47개와 qrels 50행을 구축했다.

따라서 다음 단계의 핵심은 documents.jsonl을 chunking하고, qrels의 정답 document_id를 기준으로 각 chunking 결과에 맞는 ground_truth_chunk_ids를 생성하는 것이다. 그 다음 embedding, Chroma 적재, retrieval 평가로 이어진다.

2번 완료

수집·정규화·MVP corpus·문서 스키마·평가셋/qrels

다음 단계

Chunking·정답 chunk
매핑·Embedding·Chroma·평가